Beginner Course on Microbial Genomics: Applications & Research (2026)

Module 3

An introduction to mapping

INFORMATION

Lecturer

Dr. Chung The Hao

Co-lecturer(s)

Teaching assistant

-

Câu 1: Phần mềm Seaview được dùng để làm gì?

A. Trực quan hoá dữ liệu trình tự của một đoạn gene

B. Giúp phát hiện sai khác về nucleotide trên cùng một đoạn gene giữa nhiều chủng vi khuẩn .

C. Trực quan hoá dữ liệu xếp gióng cột của một đoạn gene.

D. Tất cả câu trên đều đúng.

Câu 2: Phần mềm Artemis <u>không</u> thể làm điều nào sau đây?

A. Quan sát dữ liệu trình tự của một bộ gene tham chiếu, hoặc từ assembly của mẫu nghiên cứu
B. Tìm kiếm đoạn gene mình mong muốn dựa trên chú giải (annotation) từ file gbff
C. Quan sát sự khác biệt về GC% giữa các vùng trên cùng một genome
D. Phát hiện sự khác biệt giữa mẫu nghiên cứu và bộ gen tham chiếu
E. Quan sát sự khác biệt giữa mẫu của mình và bộ gen tham chiếu
F. Kết nối với NCBI-BLAST để tìm hit giống nhất trên cơ sở dữ liệu

Câu 3: Điều nào sau đây <u>sai</u> với lắp ráp lai?

A. Cần đầu vào là cả dữ liệu trình tự đoạn ngắn (short-read) và đoạn dài (long-read)

B. Dùng trong trường hợp muốn khẳng định gene kháng kháng sinh nằm trên plasmid hoặc nhiễm sắc thể.

C. Có thể khắc phục hạn chế do đồng nhiễm hai nhóm vi khuẩn trong một mẫu giải trình tự.

D. Số lượng contigs thường sẽ ít hơn so với lắp ráp chỉ từ đoạn ngắn.

Câu 4: Trị số nào <u>không phải</u> là output của việc kiểm tra dữ liệu bằng FastQC và MultiQC?

A. Tình trạng nhiễm bởi trình tự adaptor
B. Độ dài của đoạn đọc (read)
C. Chất lượng của đoạn đọc theo cả độ dài đoạn đọc
D. Độ bao phủ (coverage) của dữ liệu so với bộ gen tham chiếu
E. Phân bố GC% của dữ liệu

Câu 5: Sau khi đã hoàn thành assembly bằng Unicycler, tôi có thể thực hiện tác vụ nào sau đây?

A. Kiểm tra độ hoàn thiện (completeness) và tạp nhiễm (contamination) của dữ liệu bằng công cụ CheckM2
B. Phát hiện các gene kháng kháng sinh và độc lực từ bộ gen
C. Xác định dòng di truyền MLST
D. Xác định sự hiện diện của một số plasmids
E. Dùng làm dữ liệu đầu vào của chú giải (annotation)
F. Trực quan hoá bộ gen trên Artemis
G. Tất cả đều đúng

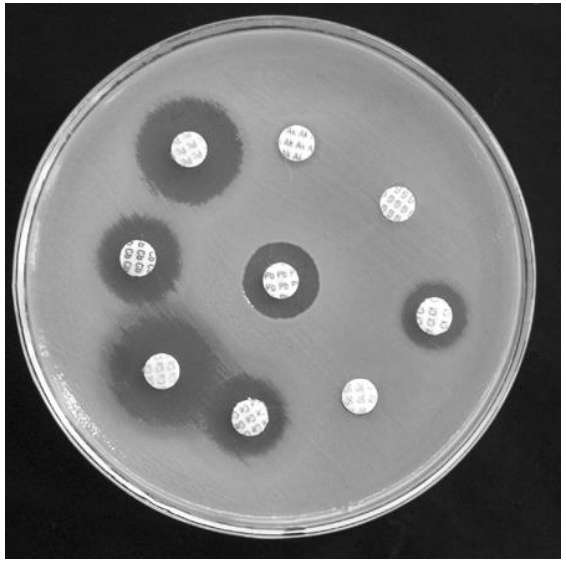
Agenda

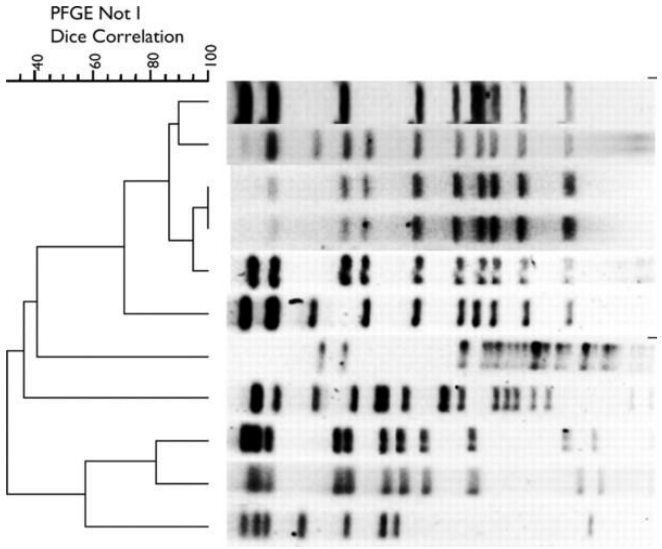
1. Today’s objective
2. Theory – mapping and SNP
3. Practical – mapping commands 1 by 1
4. Practical – variant calling file (VCF)
5. Practical – Visualizing mapping
6. Practical – Pseudogenome and alignment

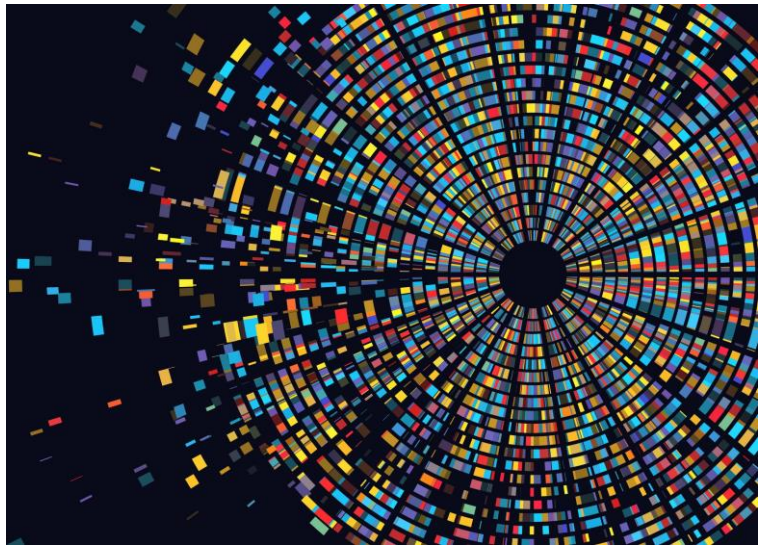
What’s in for today

- The basics of mapping (from raw read to genome alignment)
- The basics of phylogenetics (from genome alignment to trees)
- How do you arrive to a final publication-quality tree figure

Is this colony genetically related to that colony?

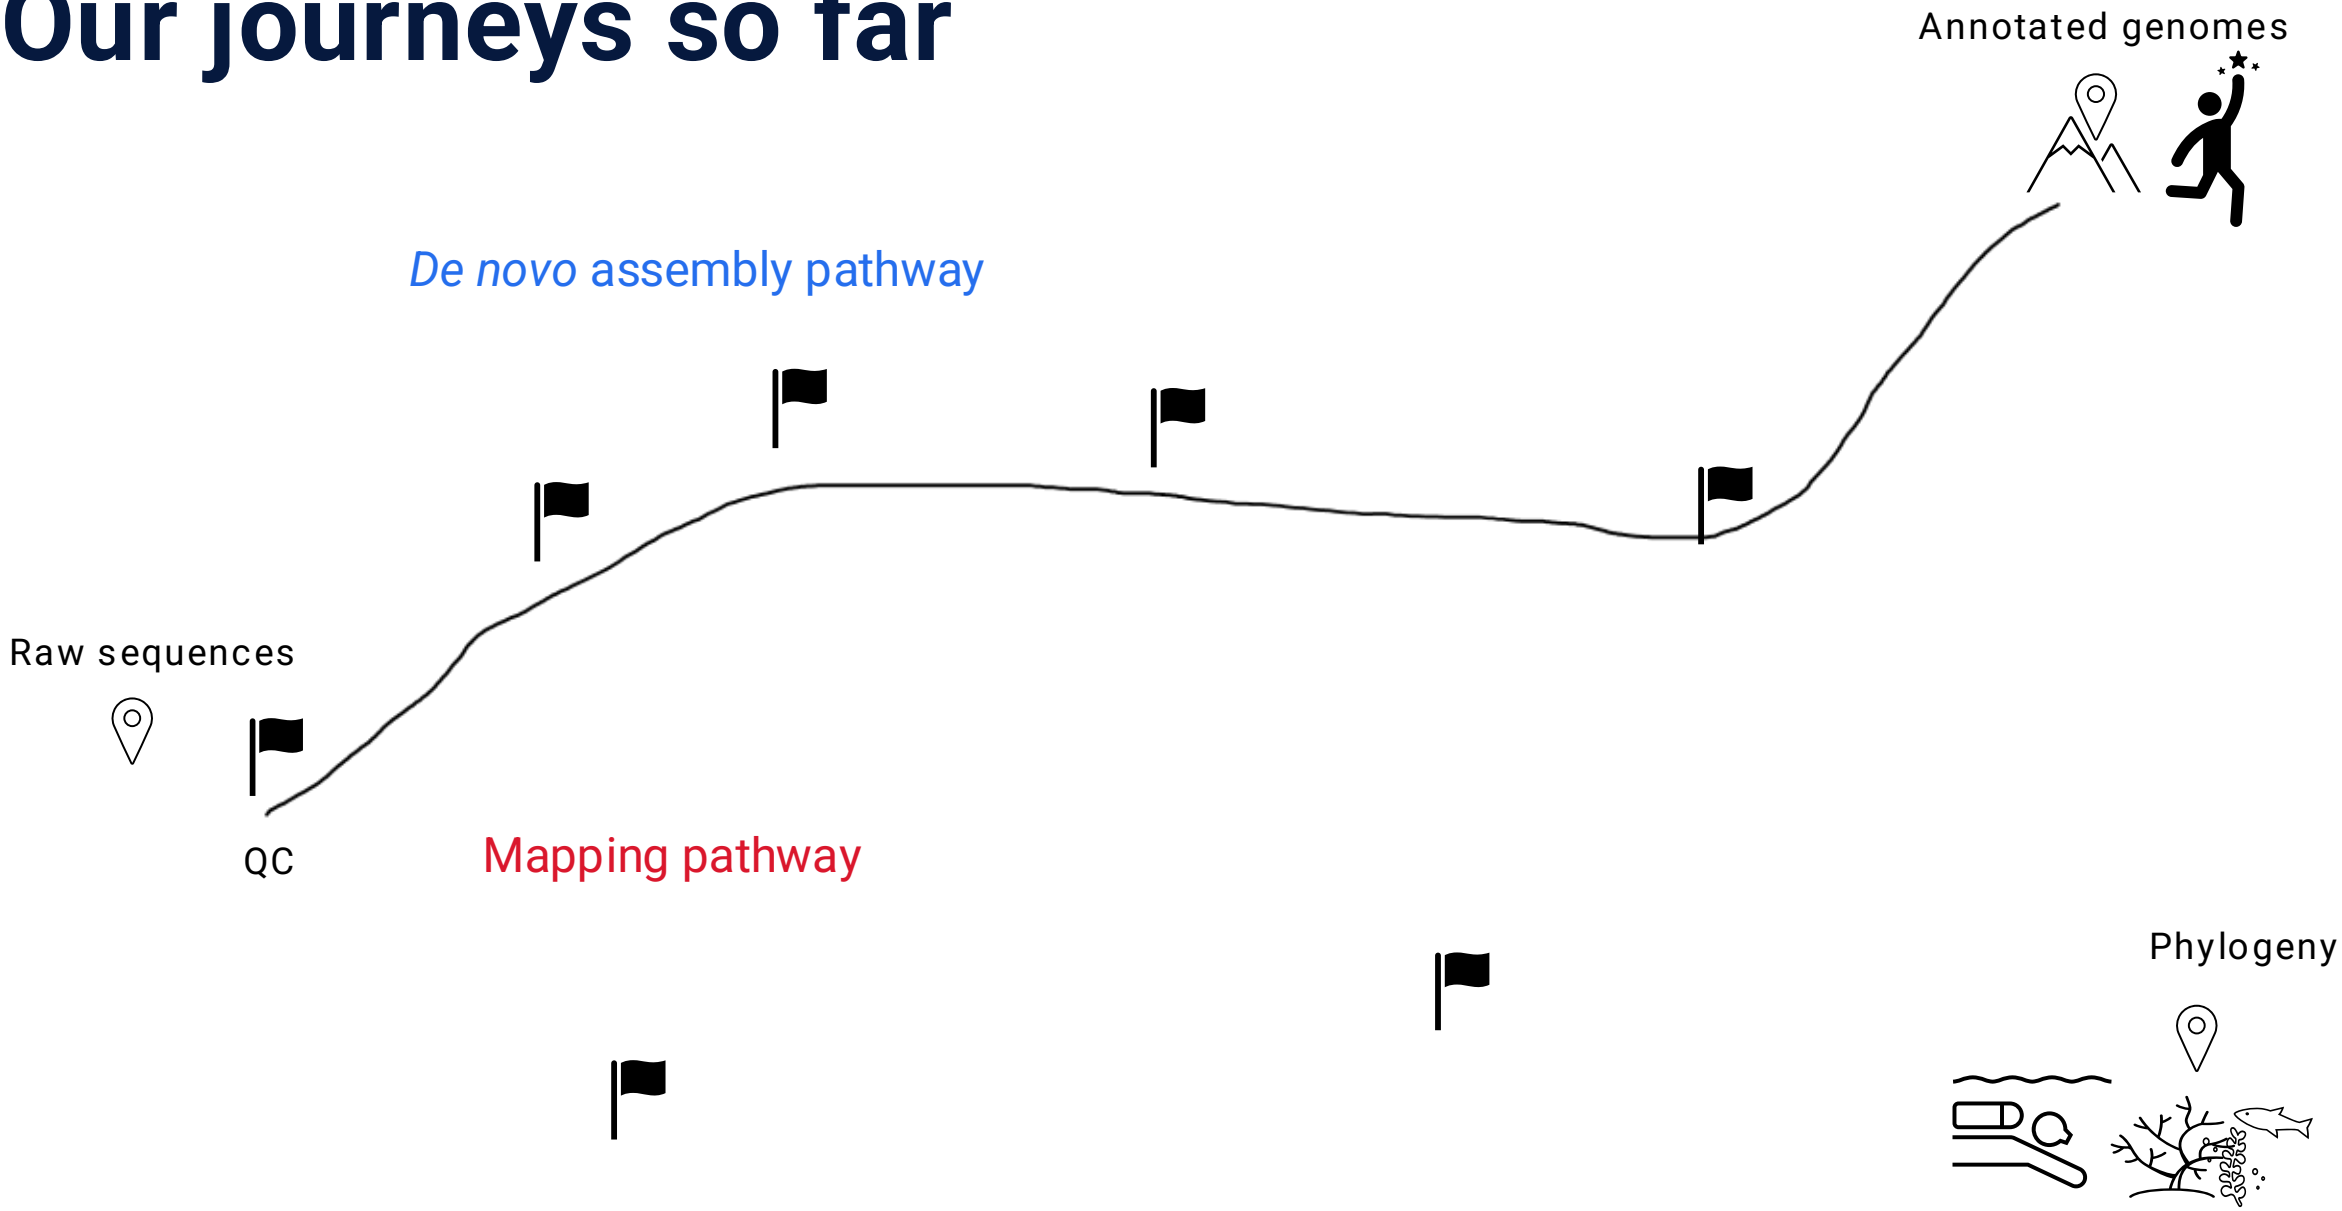






Genomic data are often fragmented due to short read sequencing, so making direct comparison between genomes can be challenging

Our journeys so far



Short read mapping

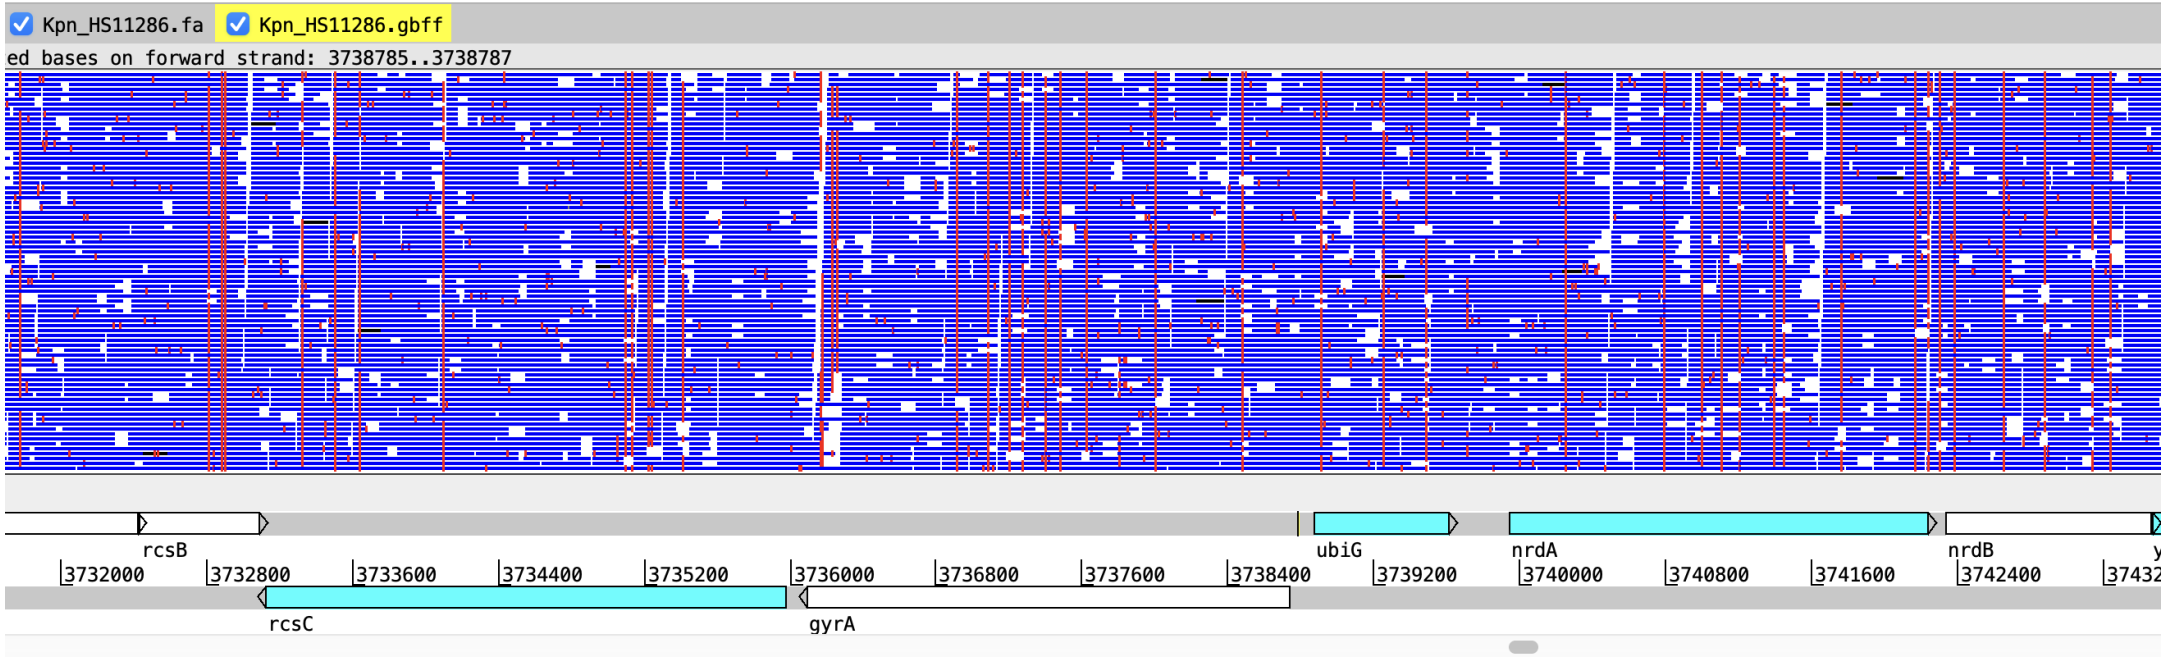
Align (map) sequencing reads to a chosen reference

Input

- A reference genome
- Sequencing reads
- User specified parameters

Output

- One or more genomic coordinates for each read.



When to use mapping

- When you have a good (*closely related*) and complete reference sequence.

- When you want to know how different your sample is compared to the reference.
  - ✓ Single nucleotide polymorphism (**SNPs**) – point mutation
  - ✓ Small or large regions of insertion/deletion.
  - ✓ But genomic rearrangement **not** confidently detected.

- When you want to build a phylogenetic relationship among your samples.

Mapping workflow

```
@IL24_5151:3:1:1553:916#9/1
NAAACTACTTACACCCACTCAGGACACCAGGGACATCATTGCTGACGCCACGGCCTCACAGTGCTGAGCTGATGAT
+
$705291596=>>>>>=>=>=>==>>>==>535:6=>=>>>>=>==5:;318656:===991/1,-0,0015204.1
@IL24_5151:3:1:2173:904#9/1
NTTTTAACCGTACTTTCACCAGGATTATCGCAGGCGGATTCCTGGTGATTAATTTCAAAAAATAGCGTTTAATCCA
+
$948883999>==>>>>=>>>=>>9>>>==>===>=>==>>:;:::===>=55:88>==>9:0;;:===>>==>>>5
@IL24_5151:3:1:2948:912#9/1
NCCACCAGACACTGTCCGCAACCCCGGTAAGGGGCCAACGTTAGAACATCAAACATTAAAGGGTGGTATTTCAAGG
+
```

Sample fastq input

Reference fasta input

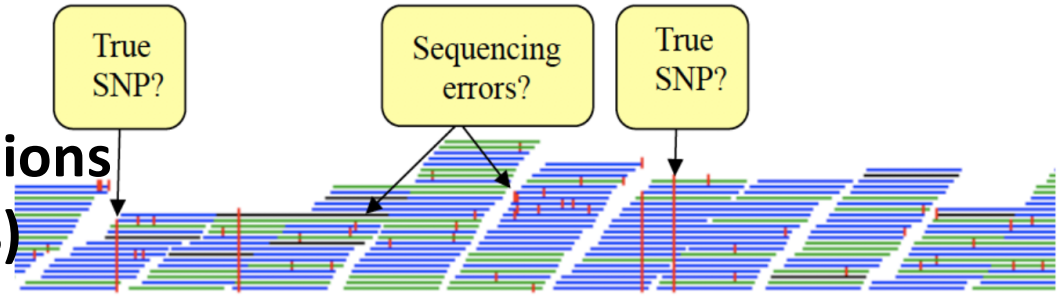
```
>reference sequence
ATTGAACGCTGGCGGCAGGCCTAACACATGCAAGTCGAGCGG
CAGCGGGAAGTAGTTTTACTTTGCCGGCGAGCGGCGGACGGG
TGAGTAATGTCTGGGAAACTGCCTGATGGAGGGATAACTACT
GGAAACGGTAGCTAATACCGCATGACCTCGTAAGAGCAAAGT
GGGGGACTTCGGGCCTCACGCCATCGGATGTGCCCAGATGGG
ATTAGCTAGTAGGTGGGGTAATGGTCACCTAGGCGACGATCC
CTAGCTGGTCTGAGAGGATGACCAGCCACACTGGAACTGAGC
ACGGTCCAGACTCCTACGGGAGGCAGCAGTGGGGAATATTGC
ACAATGGGCGCAAGCGATGCAGCCATGCCGCGTGTGTGAAGA
AGGCCTTCGGGTTGTAAAGCACTTTCAGCGAGAGGAAGGCAG
TCGTGTTAATAGCACGATTGATTGACGTTACTCGCAGAAGAAG
```



Intermediate mapping outputs:

- SAM/BAM
- VCF/BCF

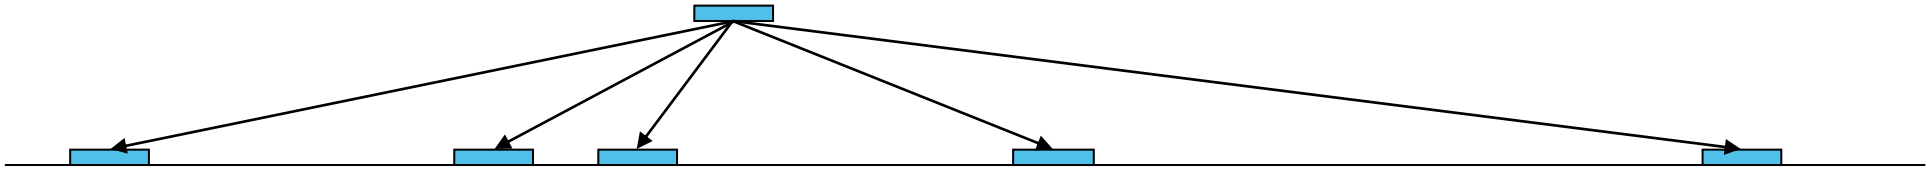
Identifying mutations (SNP, small indels)



Consensus pseudogenome fasta output

Mapping difficulties

Multiple mapping



- A single read may occur more than once in the reference genome (repeats) → unconfident mapping

- Often choose to ignore repetitive regions

Mapping difficulties

Inexact matching



- An observed read may not exactly match any position in the reference genome.
- Such mismatches may represent a SNP (single-nucleotide polymorphism) or a bad read-out.
- Trade-off between the number of mapped reads and the accuracy of mapped reads.

Advantages

- Allows high-quality identification of SNPs and mutations
- Computationally efficient
- Produce fixed length mapped sequences, with genomic coordinate identical to reference → bypass multiple sequence alignment → excellent for phylogenetics.

Limitations

- Require a high-quality chosen reference, which is important.
- Genomic regions in sequencing reads but not in reference will not be retrieved (plasmids, novel regions, etc.)
- Mostly fail to map repetitive region.

The choice of reference must be as closely related to your samples as possible!

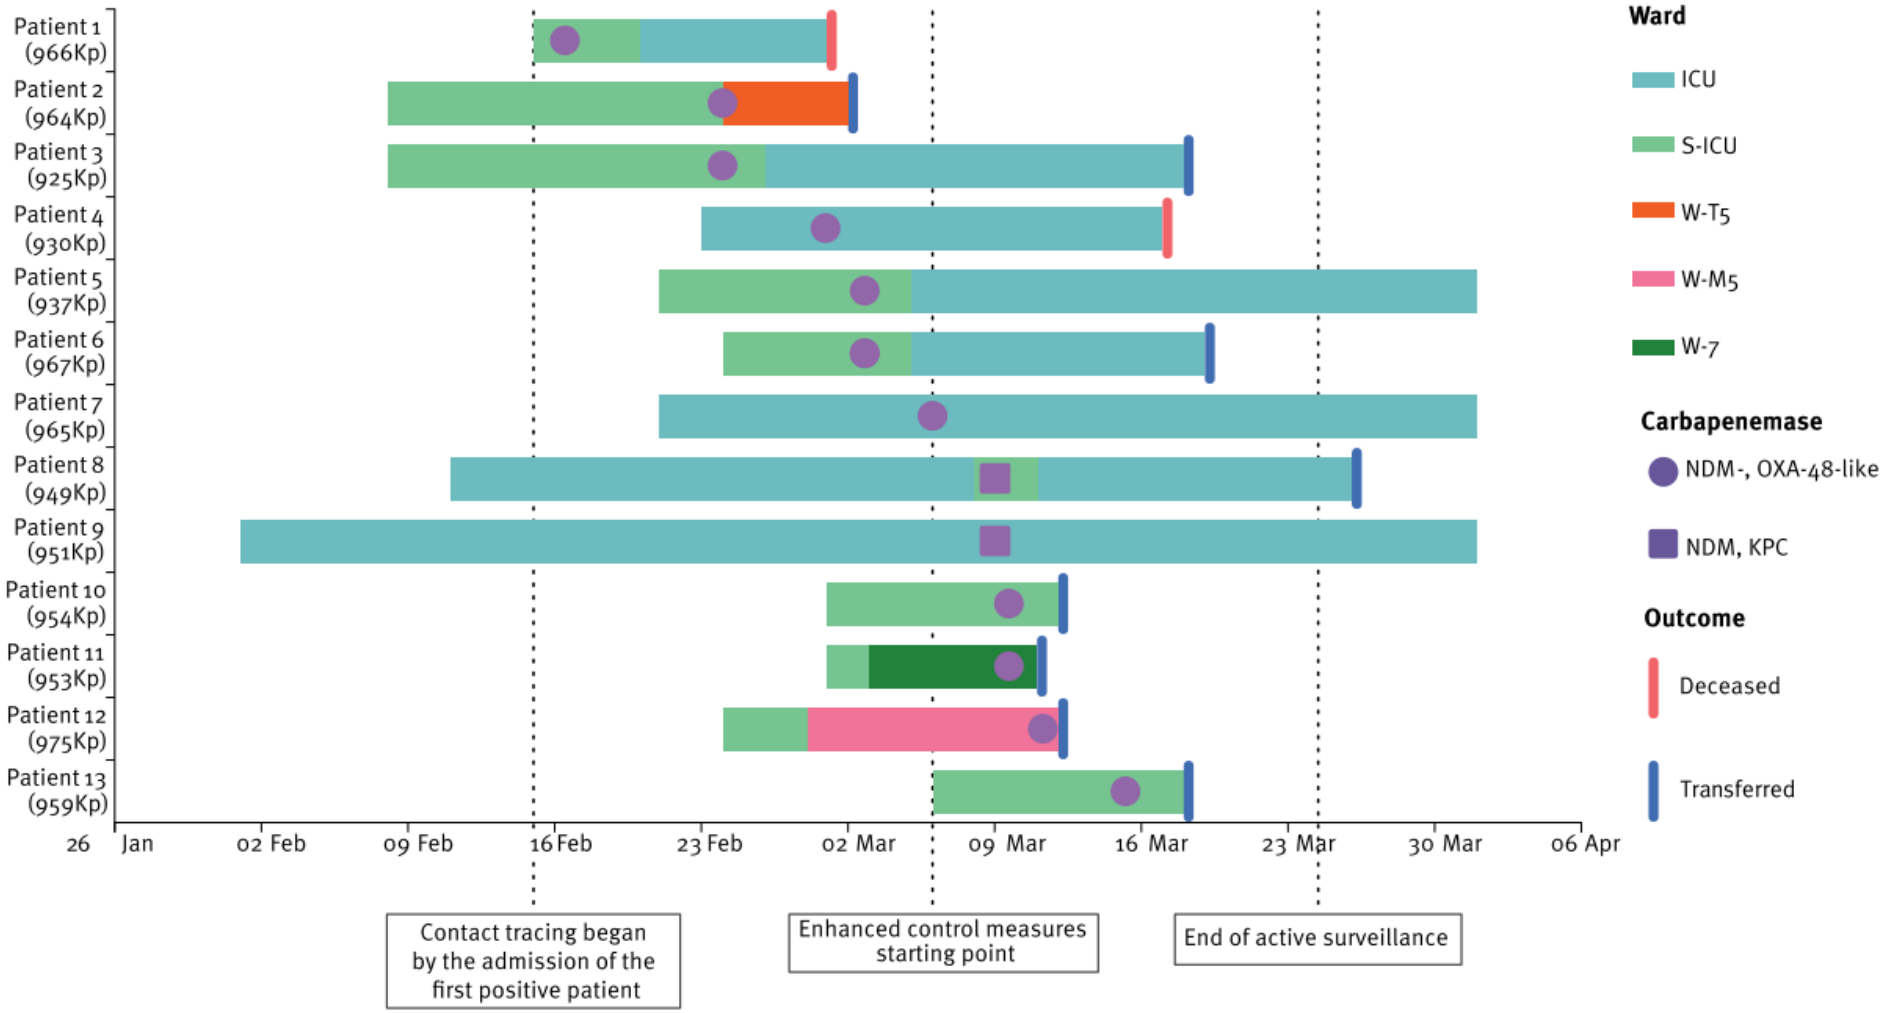
Thank you!

Question?

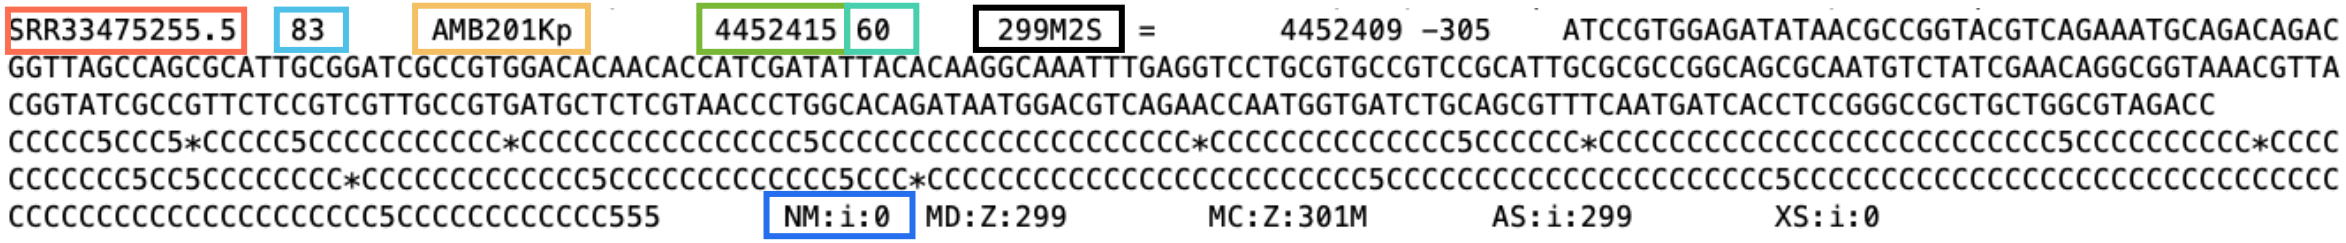


Banksy, mural in Ukraine, 2022

Jump to practical



Visualizing SAM information



Column	SAM information
1	Query read name
2	FLAG (bitwise flag describing the read). i.e: 83/99/147/163: typical properly paired reads
3	Reference sequence name
4	Left-most position mapped on reference
5	Mapping quality (Phred-scale)
6	CIGAR (**M**: aligned, S: soft-clipped, H: hard-clipped, I: insertion, D: deletion)
8	Mapped position of the mate read
9	Template length (insert size)
10	Read sequence
11	Read base quality
12	NM: information of mismatches (i:0 -> no mismatch)

Visualizing VCF information

```
#CHROM  POS     ID      REF     ALT     QUAL    FILTER  INFO    FORMAT  unknown
AMB201Kp        327178  .       C       T       802.676 PASS    AB=0;ABP=0;AC=1;AF=1;AN=1;AO=90;CIGAR=1X;DP=150;D
PB=150;DPRA=0;EPP=4.55446;EPPR=6.62942;GTI=0;LEN=1;MEANALT=1;MQM=60;MQMR=60;NS=1;NUMALT=1;ODDS=184.823;PAIRED=1;P
AIREDR=0.983333;PAO=0;PQA=0;PQR=0;PRO=0;QA=2868;QR=1970;RO=60;RPL=36;RPP=10.8276;RPPR=5.32654;RPR=54;RUN=1;SAF=47
;SAP=3.39634;SAR=43;SRF=27;SRP=4.31318;SRR=33;TYPE=snp GT:DP:AD:RO:QR:AO:QA:GL 1:150:60,90:60:1970:90:2868:-80.78
49,0
```

Column	VCF information
1	Reference sequence name
2	Position of variant
4 + 5	Reference and **ALTernate** (sample) allele
6	General quality of the variant
INFO	
AO	Mapped read count support the alternate allele
DP	Total read depth at the position
MQM	Mean mapping quality of observed alternate allele
SAF	Mapped read count on forward strand with observed alternate allele
SAR	Mapped read count on reverse strand with observed alternate allele
TYPE=	Either snp, ins (insertion), del (deletion) [freebayes specific]